

5. Метод k ближайших соседей в задачах классификации и восстановления регрессии. Теорема об оценке риска в методе ближайшего соседа. Идеи доказательства.

Метод ближайшего соседа - простейший метрический классификатор, основанный на оценивании сходства объектов. Классифицируемый объект относится к той же массе, которой принадлежат ближайшие к нему объекты обучающей выборки.

Метод k ближайших соседей - для повышения надежности классификации объект относится к той же массе, которой принадлежат большинство из его соседей - k ближайших к нему объектов обучающей выборки  $x_i$ .

Пусть задана обучающая выборка:  $\{(x^{(1)}, y^{(1)}), \dots, (x^{(N)}, y^{(N)})\}$

$x_i \in X$  - Прообразы признаков

$y \in Y$  - Выходы (responses)

~~Пусть на множестве объектов~~

$$f(x) = \frac{1}{k} \sum_{x^{(i)} \in N_k(x)} y^{(i)}$$

$$f(x) = \arg \max_y |N_k(x, y)|$$

где,  $N_k(x)$  - множество из k ближайших к  $x$  (по евклидовой расстоянию) точек из обучающей выборки.  $|N_k(x, y)|$  - количество тех точек  $x^{(i)}$  из  $N_k(x)$ , где которых  $y^{(i)} = y$ .  $f: X \rightarrow Y$  - функция, которая ~~представляет~~ ~~предлагает~~ ~~предсказывает~~ выходные данные из пространства  $Y$  по пространству  $X$  предлагаемым объектам.